

Teste de usabilidade — pasta llm/

Movie Rec Sys · FIAP Tech Challenge Fase 02 · Julho/2026

1. Para que serve este teste?

A pasta llm/ do projeto não é um ChatGPT. É uma demonstração em linguagem simples do nosso recomendador: a pessoa informa filmes que já viu e as notas que deu; o sistema sugere outros 10 títulos com nome e sinopse.

Objetivo para o time: validar o caso de uso real (“como o usuário se beneficia?”) e gerar material claro para o vídeo STAR e a entrega do Tech Challenge.

Em uma frase

Histórico de filmes + notas → perfil no modelo PyTorch → Top 10 com sinopse.

2. Como funciona (bem leigo)

- Lê um arquivo JSON com o histórico (título + nota).
- Procura cada título no catálogo MovieLens + metadados TMDB.
- Monta um “gosto médio” com os embeddings dos filmes curtidos (usuário novo / cold start).
- Ordena os demais filmes e mostra os 10 mais alinhados, com sinopse quando existe.

3. Dados usados no teste (usuária Ana)

Arquivo de entrada: llm/examples/historico_exemplo.json

O que Ana digitou	Nota	O que o sistema encontrou
Toy Story	5,0	Toy Story (1995)
Jumanji	4,0	Jumanji (1995)
Heat	5,0	Heat (1972) ← atenção: não é o Heat 1995
GoldenEye	4,5	GoldenEye (1995)
Usual Suspects	5,0	The Usual Suspects (1995)
Pulp Fiction	4,5	Pulp Fiction (1994)
Shawshank Redemption	5,0	The Shawshank Redemption (1994)
Forrest Gump	4,0	Forrest Gump (1994)

Ponto de atenção

A busca por “Heat” casou com o filme de 1972, e não com o thriller policial de 1995 (Pacino/De Niro). Isso pode ter distorcido um pouco o perfil da Ana.

4. Resultado retornado pelo nosso modelo (Top 10)

Comando: python llm/recommend_from_history.py --input llm/examples/historico_exemplo.json --k 10

#	Filme sugerido	Score	Sinopse?
---	----------------	-------	----------

1	Band of Brothers (2001)	0,970	Indisponível
2	One Shot (2004)	0,961	Indisponível
3	The Silence of the Lambs (1991)	0,958	Sim
4	Pearl Jam Live in Italy (2007)	0,956	Sim
5	People on Sunday (1930)	0,954	Sim
6	Battlestar Galactica (2003)	0,954	Indisponível
7	We Stand Alone Together (2001)	0,950	Sim
8	Star Wars: A New Hope (1977)	0,949	Sim
9	The Dark Knight (2008)	0,948	Sim
10	The Dawn Patrol (1938)	0,948	Sim

O “score” não é nota de estrela: é similaridade do perfil da Ana com o filme (quanto maior, mais alinhado ao embedding). Saída completa em `historico_exemplo_recomendacoes.json`.

5. Avaliação imparcial (GPT) sobre essas indicações

Usamos um prompt neutro (llm/examples/prompt_avaliao_imparcial.md) pedindo a outro modelo para julgar se o Top 10 faz sentido. Resumo da auditoria:

Perfil inferido da Ana

- Forte gosto por dramas e crime clássicos (Shawshank, Usual Suspects, Pulp Fiction).
- Também curte ação (GoldenEye) e aventura familiar (Toy Story, Jumanji).
- Valoriza obras influentes; não há sinal claro de guerra, sci-fi, docs ou experimental.
- Heat (1972) puxou o perfil mais para “drama” do que o Heat (1995) faria.

Classificação de cada indicação

#	Filme	Julgamento GPT
1	Band of Brothers	Neutro
2	One Shot	Neutro
3	Silence of the Lambs	Faz sentido
4	Pearl Jam (show)	Fora do perfil
5	People on Sunday	Fora do perfil
6	Battlestar Galactica	Neutro
7	We Stand Alone Together	Fora do perfil
8	Star Wars IV	Faz sentido
9	The Dark Knight	Faz sentido
10	The Dawn Patrol	Fora do perfil

Placar: 3 fazem sentido · 3 neutros · 4 fora do perfil.

Notas do avaliador

Coerência da lista: 5/10 · Nota geral do modelo neste caso: 6/10 · Veredito: PARCIALMENTE

Há acertos claros (Silence of the Lambs, Dark Knight, Star Wars), mas também ruído (show do Pearl Jam, filme mudo experimental, vários títulos de guerra). Em um streaming, a reação típica seria: gostar de 3–4, indiferente a 2–3, ignorar 3–4. Aceitável para protótipo colaborativo; abaixo de sistemas maduros.

Principais falhas apontadas

- Erro Heat 1972 vs 1995 (maior distorção do perfil).
- Excesso de guerra / documentário militar sem apoio no histórico.
- Itens de nicho pouco justificáveis (Pearl Jam, People on Sunday).
- Mistura filme + minissérie + documentário.
- Pouco aproveitamento do eixo crime/drama, o mais forte do histórico.

6. O que isso significa para o time?

- O pipeline texto → recomendação funciona de ponta a ponta (bom para o STAR).
- O modelo colaborativo acerta parte das vezes, mas ainda gera ruído — alinhado ao Model Card.

- Melhoria rápida de alto impacto: resolver melhor títulos ambíguos (ex.: Heat + ano).
- Melhorias seguintes: filtrar tipo de mídia; opcionalmente usar gênero/sinopse no ranking.
- Documentação: docs/GUIA_USABILIDADE_LLM.md e llm/examples/avaliacao_imparcial_gpt_ana.md.

7. Como reproduzir em 30 segundos

Na raiz do repositório (com model.pth e enriched_metadata.parquet):

```
python llm/recommend_from_history.py --input llm/examples/historico_exemplo.json --k 10
```

Arquivos para compartilhar / versionar

Este PDF · GUIA_USABILIDADE_LLM.md · historico_exemplo.json · historico_exemplo_recomendacoes.json · avaliacao_imparcial_gpt_ana.md · prompt_avaliacao_imparcial.md

Gerado automaticamente para o time do Tech Challenge 02 · MovieLens 20M + PyTorch MLP · pasta llm/